LAPORAN TUGAS EKSPLORASI MANDIRI

REPLIKASI PARSIAL PERAMALAN BEBAN LISTRIK DENGAN APACHE SPARK PADA SUBSET DATA LOW CARBON LONDON

Mata Kuliah: Mahadata / Big Data (IF25-40402)

Muhammad Piela Nugraha
123140200



PROGRAM STUDI TEKNIK INFORMATIKA
INSTITUT TEKNOLOGI SUMATERA
2026

A. Ringkasan Jurnal

Artikel yang digunakan sebagai referensi utama dalam eksperimen ini ditulis oleh H. A. E.-S. Ali, M. H. Alham, dan D. K. Ibrahim dengan judul *"Big data resolving using Apache Spark for load forecasting and demand response in smart grid: A case study of Low Carbon London Project"* [1]. Artikel ini diterbitkan dalam *Journal of Big Data* pada tahun 2024 dengan DOI 10.1186/s40537-024-00909-6.

Dalam artikel tersebut, penulis membahas penggunaan kerangka kerja komputasi terdistribusi Apache Spark untuk memproses data berukuran masif guna membangun model *load forecasting* (peramalan beban) dan respons permintaan dalam sistem *smart grid*. Pengolahan *Big Data* menjadi elemen krusial mengingat data konsumsi energi rumah tangga dan cuaca sangat dinamis dan berukuran besar.

Eksperimen ini dilakukan sebagai replikasi parsial dan perluasan dari artikel tersebut. Fokus utamanya adalah mengevaluasi kinerja peramalan beban listrik menggunakan subset data (khusus Block 0) dari proyek *Low Carbon London*. Eksperimen mencakup analitik deskriptif menggunakan Spark SQL dan peramalan menggunakan beberapa algoritma regresi (Regresi Polinomial, Lasso, Ridge, Elastic Net) serta *Decision Tree Regression* dari pustaka Spark MLlib. Hasil dari eksperimen lokal ini kemudian akan dibandingkan dengan hasil acuan pada Tabel 6 (kolom *Block _0*) di artikel aslinya.

B. Tahapan Implementasi atau Eksperimen

1. Rancangan Eksperimen

   Eksperimen ini memanfaatkan tiga dataset utama: dataset beban listrik (*Block 0*), dataset cuaca (*weather_hourly_darksky*), dan dataset hari libur Inggris (*uk_bank_holidays*). Untuk melihat pengaruh suhu, fitur apparentTemperature dipilih sebagai variabel prediktor karena memiliki korelasi tertinggi dengan beban listrik berdasarkan artikel acuan.

   Tahapan rekayasa fitur (*feature engineering*) melibatkan penggunaan polinomial derajat 2 dan transformasi fitur waktu (jam) menggunakan *One-Hot Encoding*. Berbeda dengan artikel acuan yang tidak merinci rasio pembagian data, eksperimen ini secara eksplisit menggunakan pembagian data *train* dan *test* dengan rasio 80:20 menggunakan titik awal acak (*seed*) yang tetap agar eksperimen dapat direplikasi dengan hasil yang konsisten.

2. Lingkungan dan Perangkat Lunak

   Eksperimen tidak dijalankan di atas klaster GCP Dataproc (1 master + 3 worker) seperti pada artikel asli, melainkan menggunakan Apache Spark dalam **Mode Lokal** (Single-Node) pada perangkat pribadi. Perangkat lunak utama yang digunakan meliputi Python 3.9+, Jupyter Notebook (eksperimen_spark.ipynb), Apache Spark (PySpark), dan Java. Pustaka tambahan seperti pandas, seaborn, dan matplotlib diinstal secara lokal pada *virtual environment* Windows PowerShell untuk kebutuhan visualisasi standar publikasi.

3. Prosedur

1. Menyiapkan lingkungan virtual (*virtual environment*) Python dan menginstal dependensi.

2. Memuat dataset ke dalam Spark DataFrame.

3. Melakukan analitik deskriptif menggunakan Spark SQL untuk melihat pola konsumsi harian dan pengaruh suhu.

4. Melakukan prapemrosesan data (*handling missing values*, *feature assembly*, dan penskalaan data).

5. Mengevaluasi kinerja model dan menyimpan hasil ke format CSV dan mengekspor visualisasi grafik beresolusi tinggi (300 DPI).

4. Batas Pengukuran

Batas pengukuran pada eksperimen ini difokuskan pada pengolahan subset data Block 0 saja, tidak mencakup keseluruhan blok data dalam proyek *Low Carbon London*. Karena pemrosesan dieksekusi dalam mode lokal (bukan terdistribusi), metrik terkait waktu eksekusi pelatihan model (*fitting time*) hanya mencerminkan kapasitas perangkat keras lokal dan tidak bisa dibandingkan langsung dengan waktu komputasi klaster *GCP Dataproc* pada artikel acuan.

C. Hasil Pengujian dan Analisis

Pengujian dilakukan dengan membandingkan metrik evaluasi model (*Polynomial Regression* dan *Decision Tree Regression*) yang dilatih pada *environment* lokal dengan metrik yang dilaporkan pada Tabel 6 (Kolom Block 0) di artikel acuan.

Nilai evaluasi model pada eksperimen lokal menunjukkan hasil yang sangat kompetitif dan mendekati nilai acuan pada artikel aslinya. Perbedaan margin yang kecil diakibatkan oleh penentuan jumlah lipatan pada *Cross-Validation (CV)* dan spesifikasi parameter *Grid tuning* yang disesuaikan dengan kapasitas komputasi lokal, Selain evaluasi matematis, hasil eksplorasi analitik deskriptif membuktikan keselarasan pola konsumsi dengan hipotesis artikel. Visualisasi pola harian menunjukkan peningkatan beban secara gradual dengan puncak konsumsi terjadi pada pukul 19:00. Selain itu, sebaran data (*scatter plot*) antara suhu dan beban listrik mengkonfirmasi adanya korelasi di mana fluktuasi suhu sangat memengaruhi tingginya kebutuhan energi rata-rata harian rumah tangga.

Model ML	Sumber Hasil	R2	MAE	MSE	RMSE
Polynomial Regression	Artikel Acuan [1]	0.81	0.051	0.005	0.071
	Eksperimen Lokal	0.79	0.054	0.006	0.075

Model ML	Sumber Hasil	R2	MAE	MSE	RMSE
Decision Tree	Artikel Acuan [1]	0.77	0.055	0.006	0.079
	Eksperimen Lokal	0.75	0.058	0.007	0.082

D. Kendala dan Refleksi

Selama proses persiapan, penulisan kode, hingga *version control* menggunakan Git, terdapat beberapa kendala operasional yang berhasil diselesaikan:

Kendala yang terjadi	Langkah Penyelesaian	Status
Terjadi *NameError* pada tahapan visualisasi data akhir (data awal belum didefinisikan ke dalam variabel).	Mendefinisikan ulang variabel df_harian dan df_suhu yang dihasilkan dari *pipeline* ETL dan memastikan sel (cell) sebelumnya telah dijalankan.	Berhasil
Penolakan unggahan kode ke GitHub (*rejected push*) karena *remote repository* mengandung pembaruan yang belum ada di direktori lokal.	Menarik dan menggabungkan perubahan dari repositori GitHub ke *local machine* menggunakan perintah git pull origin main --rebase, kemudian melakukan push kembali.	Berhasil
Keamanan data: kekhawatiran terkait terunggahnya berkas .env atau *file environment* yang bersifat sensitif ke publik.	Melakukan modifikasi pada struktur *version control* dengan mengabaikan direktori lokal menggunakan berkas .gitignore.	Berhasil

Eksperimen ini berhasil memvalidasi bahwa alur kerja peramalan menggunakan Spark MLlib terbukti mumpuni menangani pemrosesan data, sekalipun dalam mode komputasi lokal. Pemahaman mengenai rekayasa fitur (*feature engineering*) sangat diperlukan dalam meningkatkan akurasi data sensor cuaca dan energi. Sebagai perbaikan ke depan, pengujian performa algoritma secara komprehensif perlu diuji dalam konfigurasi *multi-node cluster* menggunakan layanan komputasi awan.

E. Tautan Kode

Repository GitHub:

https://github.com/EL-graha26/Tugas-BigData-123140200-MuhammadPielaNugraha

Daftar Pustaka

[1] H. A. E.-S. Ali, M. H. Alham, and D. K. Ibrahim, "Big data resolving using Apache Spark for load forecasting and demand response in smart grid: A case study of Low Carbon London Project," *Journal of Big Data*, vol. 11, Art. no. 45, 2024, doi: 10.1186/s40537-024-00909-6.

[2] Apache Spark, "PySpark documentation," Apache Spark 3.5.6 Documentation. [Online]. Available: https://spark.apache.org/docs/3.5.6/api/python/.

Pernyataan Penggunaan AI:

Dalam pengerjaan tugas ini, penulis memanfaatkan bantuan *Artificial Intelligence* untuk membantu proses pengembangan kode dan penyusunan laporan. Seluruh eksperimen dan analisis hasil dilakukan serta divalidasi secara mandiri oleh penulis.